


PAPER VISUAL GUIDE

π0.5 论文可视化精读

从异构共训练到层次式连续动作生成

pi0.5 Inference: semantic planning conditions continuous control



Factorization: $p(\text{action, subtask} \mid \text{observation, task}) = p(\text{action} \mid \text{observation, subtask}) \cdot p(\text{subtask} \mid \text{observation, task})$

核心主线：语义子任务先行，连续动作块随后生成

一句话结论 π0.5 的关键不是单个新层，而是“FAST 离散预训练 + 异构数据共训练 + Flow Action Expert 后训练 + 高低层语义分解”的完整训练配方。

适合快速复习、论文汇报与 OpenPI 代码对照。依据论文 v1（2025-04-22）整理。

1. 先看懂整张模型图





Fig. 3: **Model overview.** $\pi_{0.5}$ is trained in two stages. First, a pre-training stage combines all of the different data sources to produce an initial VLA with discrete tokens. This stage uses data from diverse robotic platforms, high-level semantic action prediction, and data from the web. Robotic data uses the FAST action tokenizer to represent actions as discrete tokens [64]. Second, a post-training stage specializes the model for low-level and high-level inferences for mobile manipulation, leveraging the most task-relevant data, including verbal instructions from human supervisors. This stage uses flow matching to represent the action distribution, enabling efficient real-time inference and the ability to represent fine-grained continuous action sequences. At inference time, the model first infers a high-level subtask, and then predicts the actions based on this subtask.

论文图 3: 预训练、后训练与推理的总体关系 (原论文第 4 页)

图的左半边是“把不同监督统一成 token 学习”，右半边是“把已学到的 VLA 接上连续动作专家”。预训练使用 FAST 将动作 chunk 压缩为离散 token，因此动作、语言、边界框和问答都可以使用 next-token prediction。后训练再增加 300M Action Expert，使推理时无需逐个生成 FAST token，而是用 10 步 Flow Matching 得到连续动作块。

不要误解 这里的 Action Expert 更接近按模态固定分开的 Transformer 参数组，不是带 router、由 token 动态选择专家的传统稀疏 MoE。

2. 完整数据流与概率分解




一次推理的数据流：观测 → 子任务 → 条件动作流

模型输入观测 $\mathbf{o}_t = [I_t^1, \dots, I_t^n, q_t]$ 和总体任务 ℓ ，先生成语义子任务 ℓ ，再生成动作块 $\mathbf{a}_{\{t:t+H\}}$ 。论文使用以下分解：

$$\pi(\mathbf{a}, \ell \mid \mathbf{o}, \ell) = \pi(\mathbf{a} \mid \mathbf{o}, \ell) \cdot \pi(\ell \mid \mathbf{o}, \ell)$$

- 高层策略： $\pi(\ell \mid \mathbf{o}, \ell)$ ，回答“下一步该做什么”。
- 低层策略： $\pi(\mathbf{a} \mid \mathbf{o}, \ell)$ ，回答“这个子任务具体怎样执行”。
- 建模假设中低层动作不再直接依赖总任务 ℓ ，而依赖子任务 ℓ 。高层输出因此是可解释的条件瓶颈。

3. 两阶段训练为什么必要



两阶段训练：先吸收异构知识，再获得连续动作实时生成能力

阶段一（280k steps）

MM、ME、CE、HL、WD 数据被统一为自回归 next-token prediction；动作通过 FAST 离散化。此时 $\alpha=0$ ，连续 Action Expert 尚未训练。论文强调第一阶段 97.6% 的样本并非目标移动机器人家务数据。

阶段二（80k steps）

使用 MM、ME、HL、WD 和 verbal instruction（VI），移除 CE，并过滤失败或过长 episode。Action Expert 随机初始化，联合优化 token 交叉熵和连续 Flow Matching 损失， $\alpha=10$ 。

4. Loss 与梯度链路

$$L = L_{\text{CE}}(\text{text}, \text{box}, \text{subtask}, \text{FAST}) + \alpha \cdot \|(\omega - a) - f^a_{\theta}(a^{\tau, \omega}, o, \ell)\|^2$$

- L_{CE} 更新 VLM 的文本/视觉/FAST 预测相关权重，维持语义能力和离散动作能力。
- Flow MSE 更新 Action Expert，并通过共享 self-attention 条件依赖 VLM prefix。
- 论文明确 $M+H \leq N$ ：并非所有输入位置都有直接监督。

公式审计 论文给出的路径 $a^{\tau, \omega} = \tau a + (1-\tau)\omega$ 的导数是 $a - \omega$ ，但正文与损失写的 target 是 $\omega - a$ 。符号表面相反，必须结合 ODE 积分方向或代码约定核实。

5. Attention Mask：为什么不会动作泄漏




Fig. 18: Example of the $\pi_{0.5}$ attention masking pattern.

论文图 18: Prefix、FAST 动作与 Action Expert 的可见性 (附录 E)

Query / Key	Prefix	FAST	Expert
Prefix	双向可见	不可见	不可见
FAST	可见	仅过去	不可见
Expert	可见	不可见	块内互看

FAST 与连续动作两条分支共享图像、prompt 和 state 前缀，但彼此不可见。这避免连续 Action Expert 在训练中读取 FAST 真值动作。信息整体从 VLM 单向流向 Action Expert；VLM token 不读取 Expert token。

6. 数据配方：每种数据贡献什么



Fig. 4: Examples from pre-training and post-training tasks. $\pi 0.5$ is pre-trained on data from mobile manipulators (MM), non-mobile robots in diverse environments (ME), and cross-embodiment data collected under laboratory conditions (CE), as well as high-level subtask prediction (HL), and multi-modal web data (WD). In a post-training phase, we additionally use verbal instructions (VI) and omit the laboratory cross-embodiment data (CE) to focus the model

论文图 4：预训练与后训练的数据类型（原论文第 6 页）

MM: 约 400 小时、约 100 个家庭环境的目标移动机器人数据。

ME: 多家庭环境的静态机器人数据，提供场景多样性和跨本体技能迁移。

CE: 实验室跨本体、多任务数据，包含 OXE；只用于预训练。

HL: 人工语义子任务与相关 bounding boxes，训练高层规划并改善低层表征。

WD: caption、VQA、object localization，主要改善 OOD 物体语义与语言跟随。

VI: 人类用语言逐步“遥操作”已训练低层策略，示范高层子任务选择。

7. 一次完整推理

1. 读取四路图像、本体状态和总任务，例如“clean the bedroom”。
2. 高层使用全部四个相机，自回归输出下一子任务，例如“pick up the pillow”。
3. 低层使用前视与双腕相机，将子任务作为条件。
4. 从高斯噪声动作块开始，Action Expert 进行 10 次 Flow Matching 积分。
5. 输出长度 50 的连续动作 chunk；控制目标以 50 Hz 下发，由简单 PD 跟踪。

论文未说明 chunk 每轮实际执行多少步、何时重规划、是否重叠，以及高层子任务刷新频率。不能仅凭 $H=50$ 推断整块必然完整开环执行。

8. 实验结论与正确解读

- 训练环境从 3 增加到 104 个时，未见环境性能持续提高；完整配方接近见过测试家庭的对照模型。
- 去掉 ME 或 CE 均明显下降，同时去掉两者更严重，支持跨本体迁移的重要性。
- WD 对平均家务进度未必显著，但对 OOD 物体语言跟随和高层策略很重要。
- 完整 π 0.5 优于 π 0 与 π 0-FAST+Flow，说明收益不只是 FAST 或 Flow，而是完整共训练配方。
- implicit HL 在推理时不显式生成子任务，但训练时保留 HL 数据，表现第二好：高层监督的表征学习收益大于单纯显式规划收益。

谨慎解读 π 0.5 优于 human HL 并不直接证明模型规划超过人类。人工子任务标签的形式、切换时机以及
与低层策略训练分布的匹配都会影响该基线。

9. 与公开 OpenPI 的边界

公开 OpenPI 的常规 π 0.5 微调不应被视为论文系统的完整复现。论文系统还依赖两阶段异构共训练、HL/WD/VI 数据、显式高层子任务生成以及在线高低层调度。只在自己的 LeRobot 数据上做连续动作 loss 微调，本质上是基于 π 0.5 权重的低层策略适配。

10. 五条记忆卡

- 核心是训练配方，不是单个网络层。
- FAST 负责高效吸收异构数据，Flow Matching 负责连续动作快速推理。
- 高层与低层由同一 VLA 表示，通过语义子任务做概率分解。
- Attention mask 隔离两种动作表示，避免信息泄漏。
- OpenPI 常规微调不等于论文完整 π 0.5 系统。

证据位置

图 3 与两阶段总览：第 4 页；架构、概率分解与 Loss：第 5 页；数据配方：第 6–7 页；实验与消融：第 8–11 页；技术细节与 Attention Mask：第 19 页，附录 E。